2017 China Kubernetes End User Conference
kubernetes 中国用户大会
KEUC 2017
2017.10.15 / 中国 · 杭州

七牛AI训练业务的K8S实践

七牛容器云 - 陆龙文

主办：CLOUD NATIVE COMPUTING FOUNDATION
caicloud 才云
K8S 中国社区

AI训练的业务情况

kubernetes 的优势

基于 kubernetes 的AI训练

一次踩坑经历

接下来的工作

主办：

AI训练流程

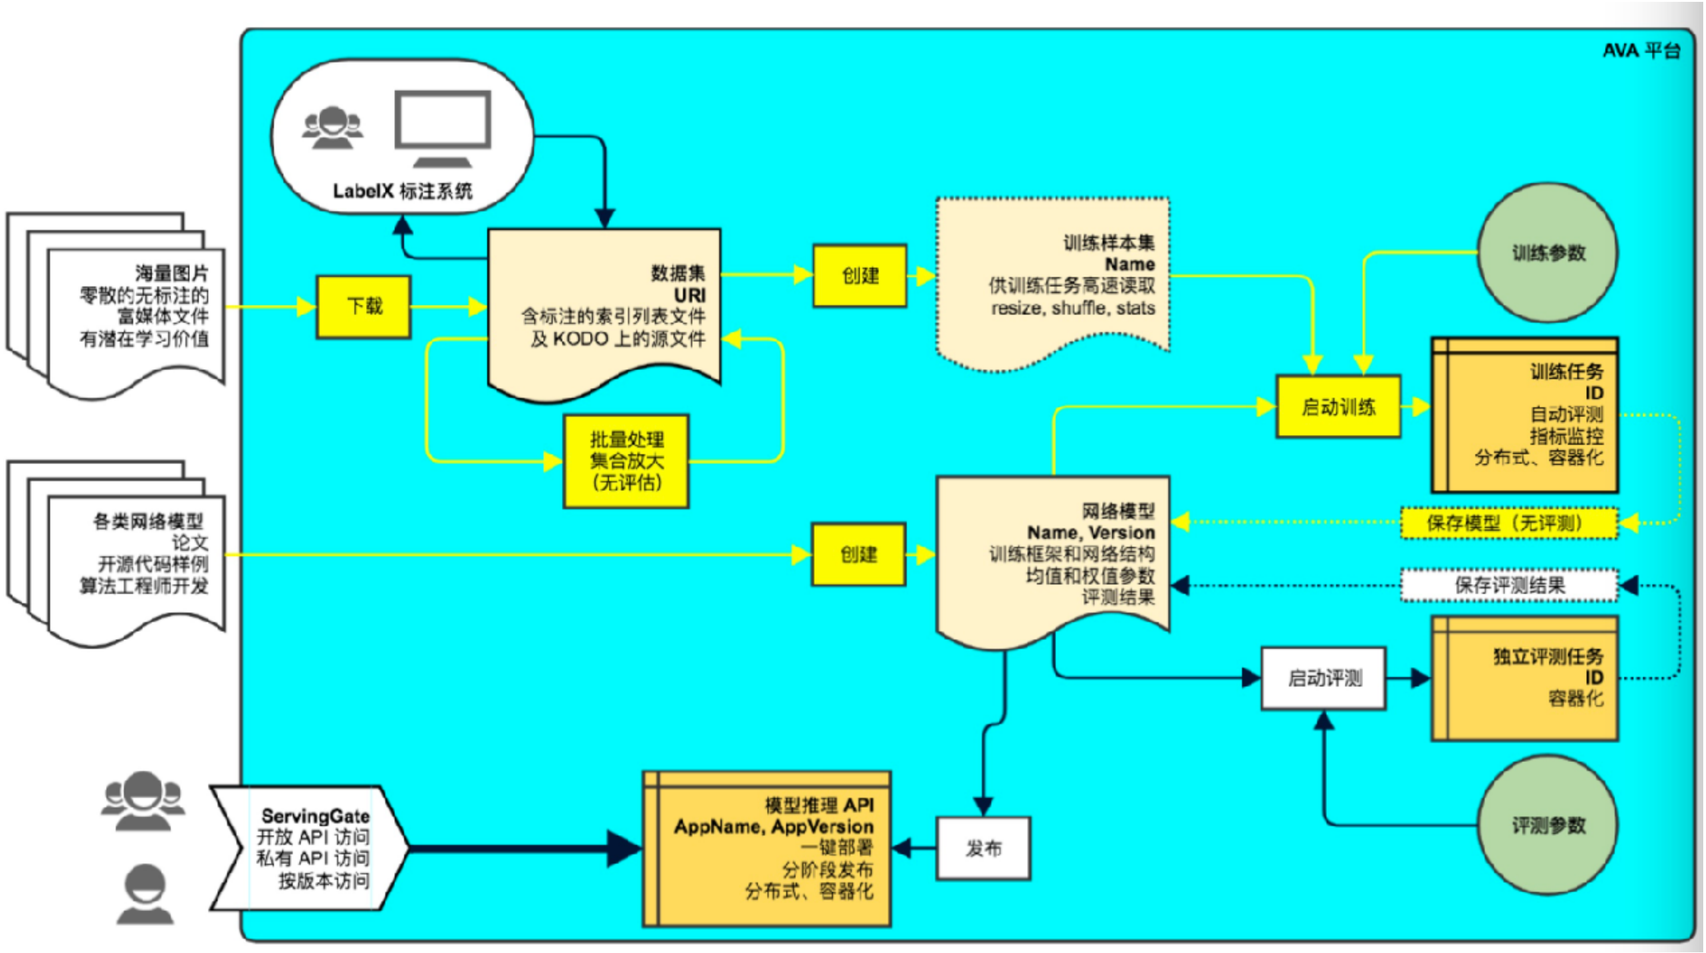
AVA 平台
LabelX 标注系统
海量图片
零散的无标注的
富媒体文件
有潜在学习价值
下载
数据集
URI
含标注的索引列表文件
及 KODO 上的源文件
批量处理
集合放大
(无评估)
创建
训练样本集
Name
供训练任务高速读取
resize, shuffle, stats
训练参数
启动训练
训练任务
ID
自动评测
指标监控
分布式、容器化
各类网络模型
论文
开源代码样例
算法工程师开发
创建
网络模型
Name, Version
训练框架和网络结构
均值和权值参数
评测结果
保存模型（无评测）
保存评测结果
启动评测
独立评测任务
ID
容器化
评测参数
ServingGate
开放 API 访问
私有 API 访问
按版本访问
模型推理 API
AppName, AppVersion
一键部署
分阶段发布
分布式、容器化
发布

AI训练迭代

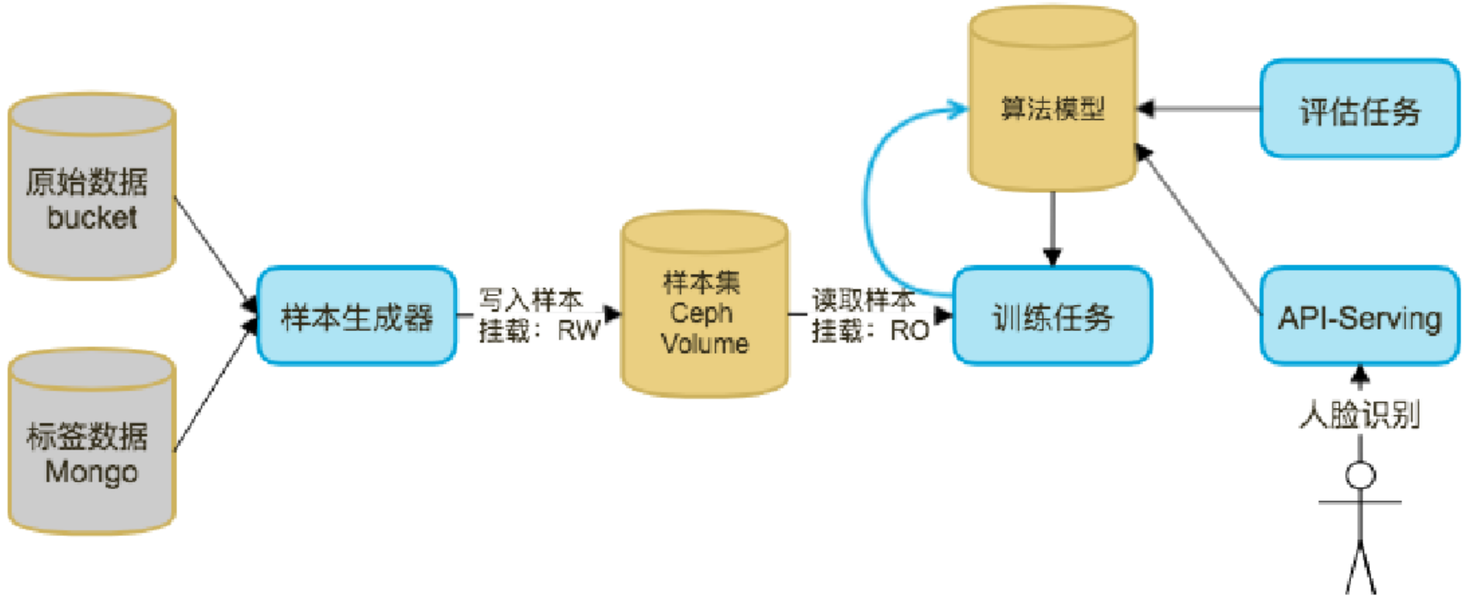
原始数据
bucket
标签数据
Mongo
样本生成器
写入样本
挂载：RW
样本集
Ceph
Volume
读取样本
挂载：RO
算法模型
训练任务
评估任务
API-Serving
人脸识别

AI训练的业务情况

kubernetes 的优势

基于 kubernetes 的AI训练

一次踩坑经历

接下来的工作

主办：

AP训练的痛点-流程

训练流程

- 算法工程师通过脚本控制，管理困难
- 失败重试需要人工介入

GPU 资源管理

- 资源多人共用，协调耗费精力
- 资源释放不及时，利用率低

存储

- IOPS要求高，突发读写，目标数据大
- NFS服务单点，扩展性差，性能无法满足需求

kubernetes 的优势

GPU 支持

- kubernetes 初步支持 GPU 资源调度，并且仍在快速完善中

Job 调度

- Job 类型的任务调度方式与训练任务场景相性相合

日志监控

- kubernetes 与 Prometheus、Elastic Search 配合良好

AI训练的业务情况

kubernetes 的优势

基于 kubernetes 的AI训练

一次踩坑经历

接下来的工作

主办：

AI训练 - 生成样本集

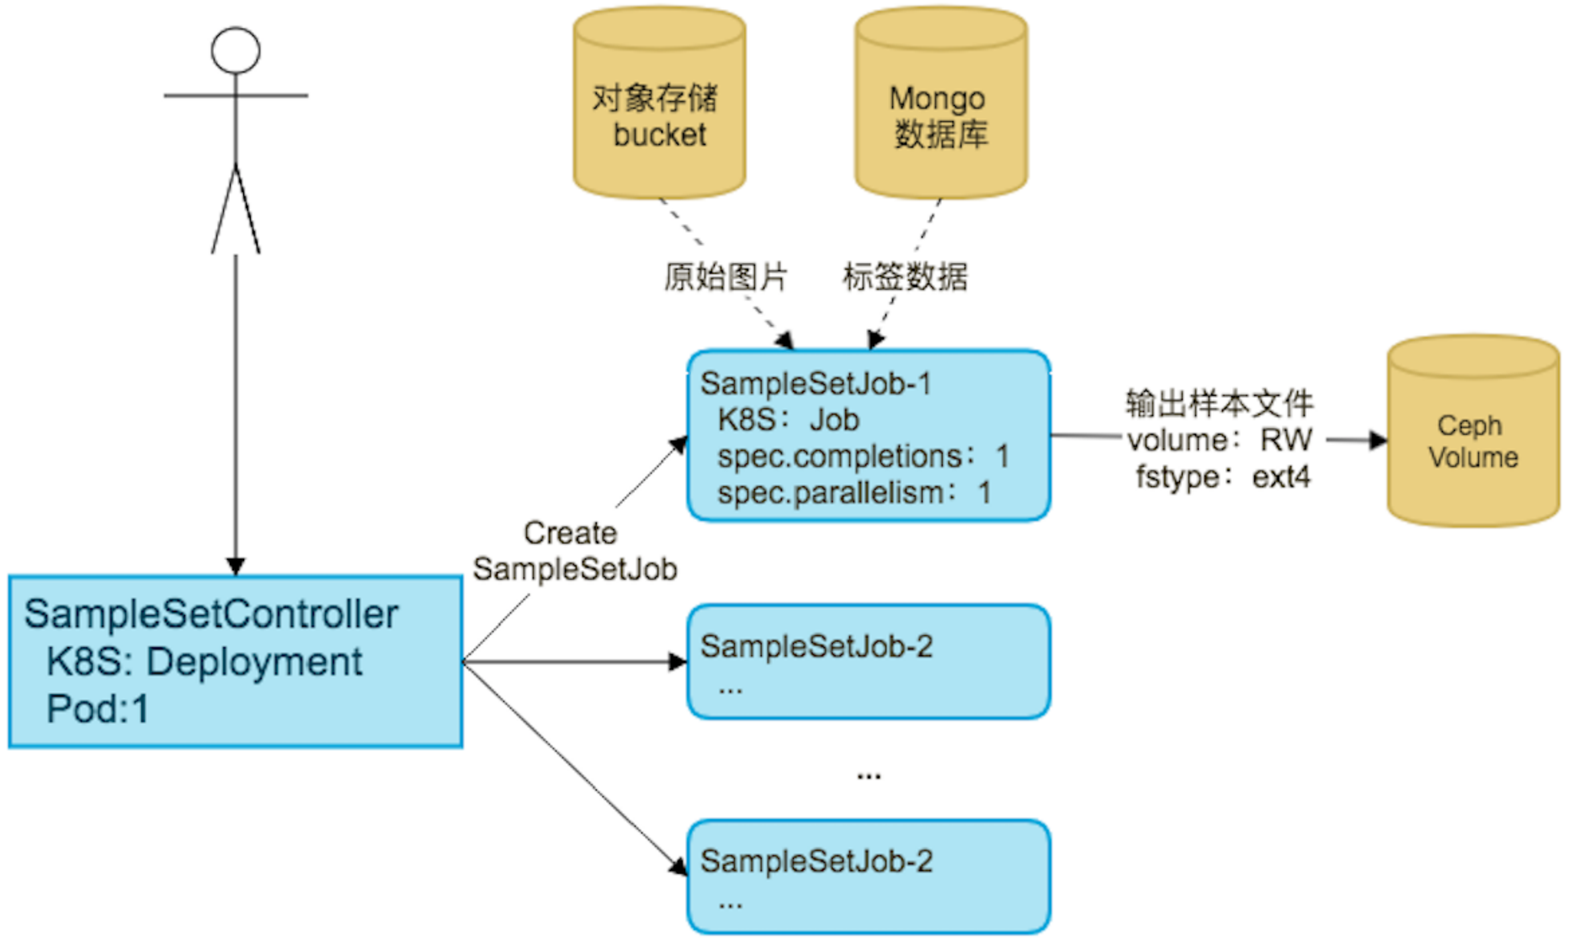
对象存储
bucket
Mongo
数据库
原始图片
标签数据
SampleSetJob-1
K8S： Job
spec.completions： 1
spec.parallelism： 1
输出样本文件
volume： RW
fstype： ext4
Ceph
Volume
Create
SampleSetJob
SampleSetController
K8S: Deployment
Pod:1
SampleSetJob-2
...
...
SampleSetJob-2
...

AI训练 - 启动训练任务

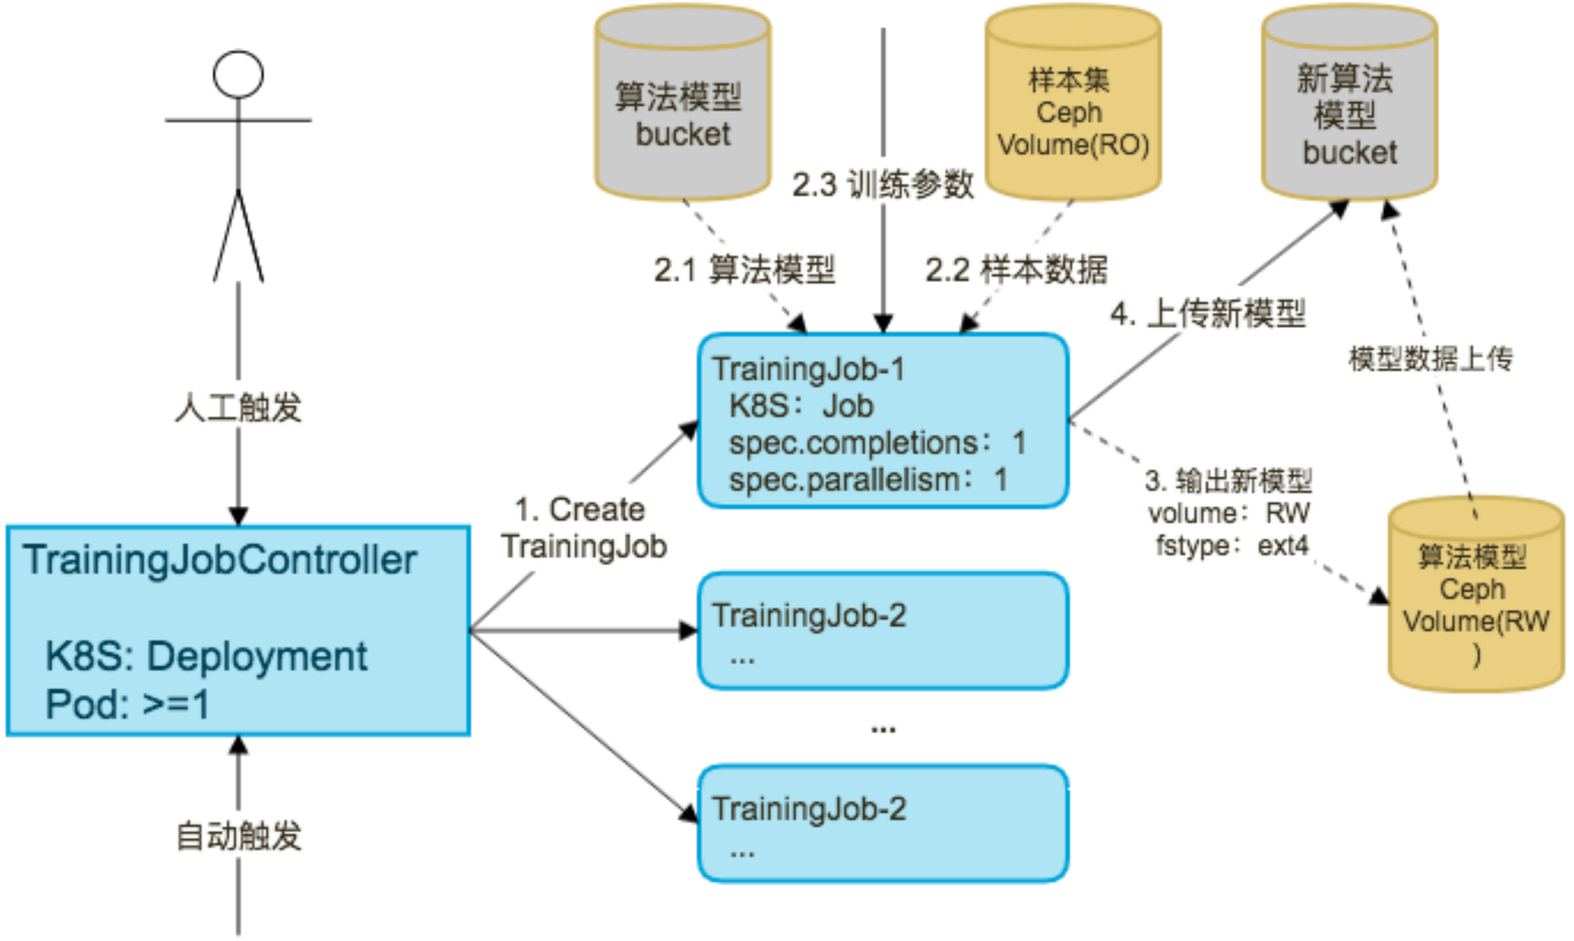
算法模型
bucket
样本集
Ceph
Volume(RO)
新算法
模型
bucket
2.3 训练参数
2.1 算法模型
2.2 样本数据
4. 上传新模型
模型数据上传
人工触发
TrainingJob-1
K8S：Job
spec.completions：1
spec.parallelism：1
1. Create
TrainingJob
3. 输出新模型
volume：RW
fstype：ext4
TrainingJobController
K8S: Deployment
Pod: >=1
TrainingJob-2
...
...
TrainingJob-2
...
自动触发
算法模型
Ceph
Volume(RW
)

AI训练 - 使用 CEPH 存储

数据集规模大：10T+

- 网络共享卷，无需拷贝数据
- 水平扩展性良好

读写控制：

- 支持一写或者多读
- 生成样本时，不能训练
- 生成样本后，允许多个 Job 并发训练

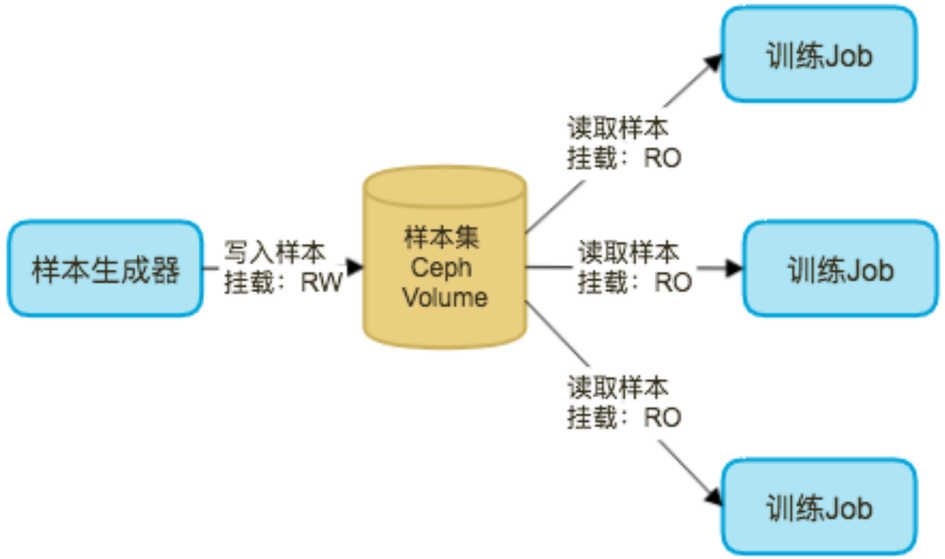

CEPH on Kubernetes 的改进

imageFormat 2 的支持

支持 Volume cloning

RDB Provisioner out-of-tree 支持

- 与 K8S 解耦，独立外部进程运行
- 通过 list-watch apiserver 来操作 RBD

GPU 资源规划与分配

使用 Node Label + Node Selector

- Node Label 标注拥有 GPU 资源的物理机
- Node Selector 调度需求 GPU 的训练任务

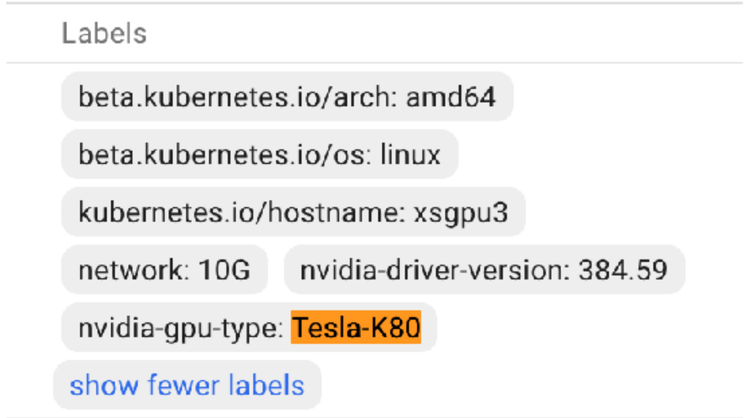

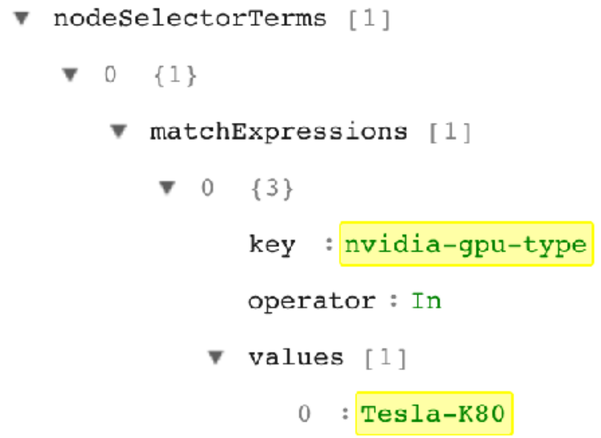

GPU 资源规划与分配

使用 limits + request 合理分配资源

- limits 标注任务使用资源上限
- request 标注任务所需资源
- 实现合理超卖，充分利用资源

```
▼ limits {3}
    alpha.kubernetes.io/nvidia-gpu : 1
    cpu : 800m
    memory : 80Gi
▼ requests {3}
    alpha.kubernetes.io/nvidia-gpu : 1
    cpu : 200m
    memory : 1Gi
```

Nvidia GPU Driver

需求：

- Nvidia 驱动：硬件相关（K80、M40），部署于物理机上
- 训练容器：硬件相关，需要对应的的驱动

实现方式：

- 将物理机上的驱动安装路径定义为 HostPath Volume
- 运行容器时候挂载到容器内

```
▼ 2  {2}
    name : path--usr-local-nvidia
  ▼ hostPath {1}
      path : /var/lib/nvidia-docker/volumes/nvidia_driver/latest
```

```
▼ volumeMounts [5]
  ▶ 0  {3}
  ▶ 1  {2}
  ▼ 2  {3}
      name : path--usr-local-nvidia
      readOnly : true
      mountPath : /usr/local/nvidia
```

监控方案

物理机监控

- 基于 Prometheus Node Exporter
- 获取 CPU、内存、磁盘、网络维度信息

容器监控

- kubelet 内嵌 cadvisor

监控注册

- Prometheus 从 kubernetes apiserver 获取需监控的资源

GPU 监控

- 为社区贡献：GPU 使用率、现存使用率、GPU核心使用率

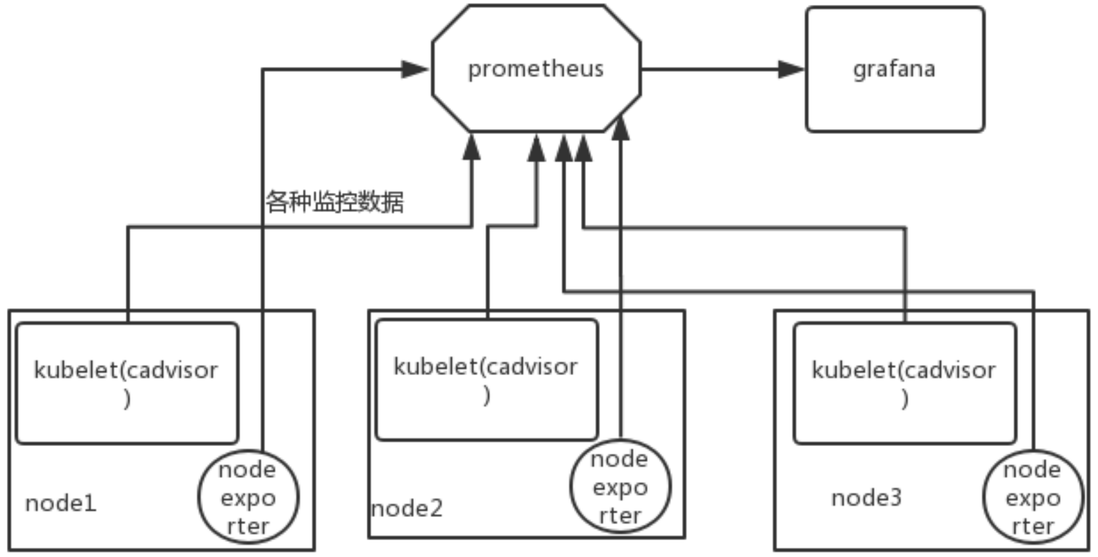

基于 Pandora 日志存储、分析

基于ElasticSearch自研Sharding集群，承载七牛公有云所有日志

用户通过日志分析，快速定位事故原因、持续时间、影响范围等

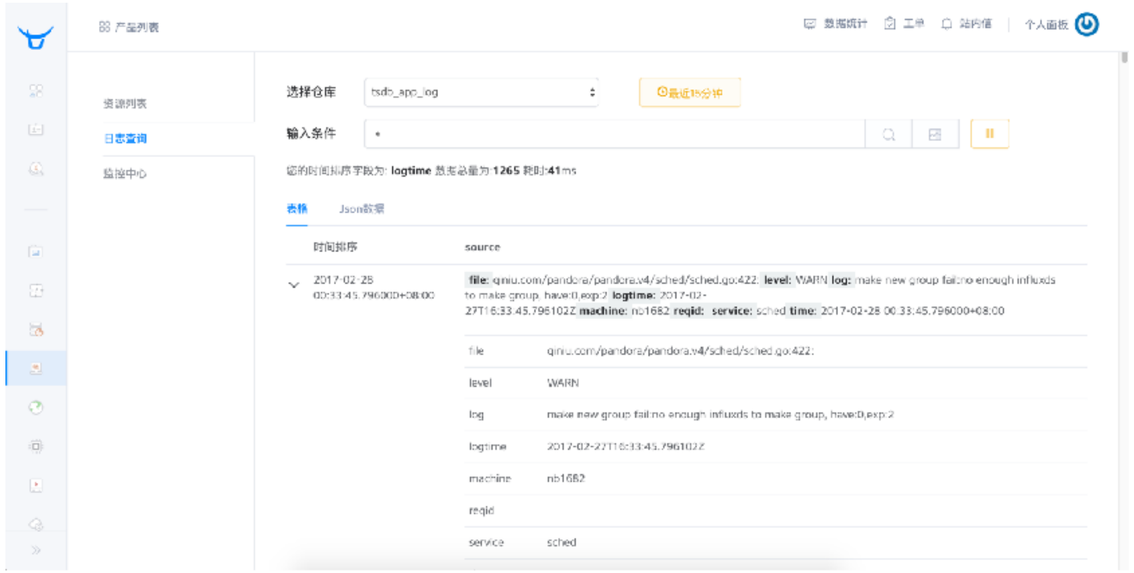

主办：

AI训练的业务情况

kubernetes 的优势

基于 kubernetes 的AI训练

一次踩坑经历

接下来的工作

主办：

容器挂载 CEPH 过程

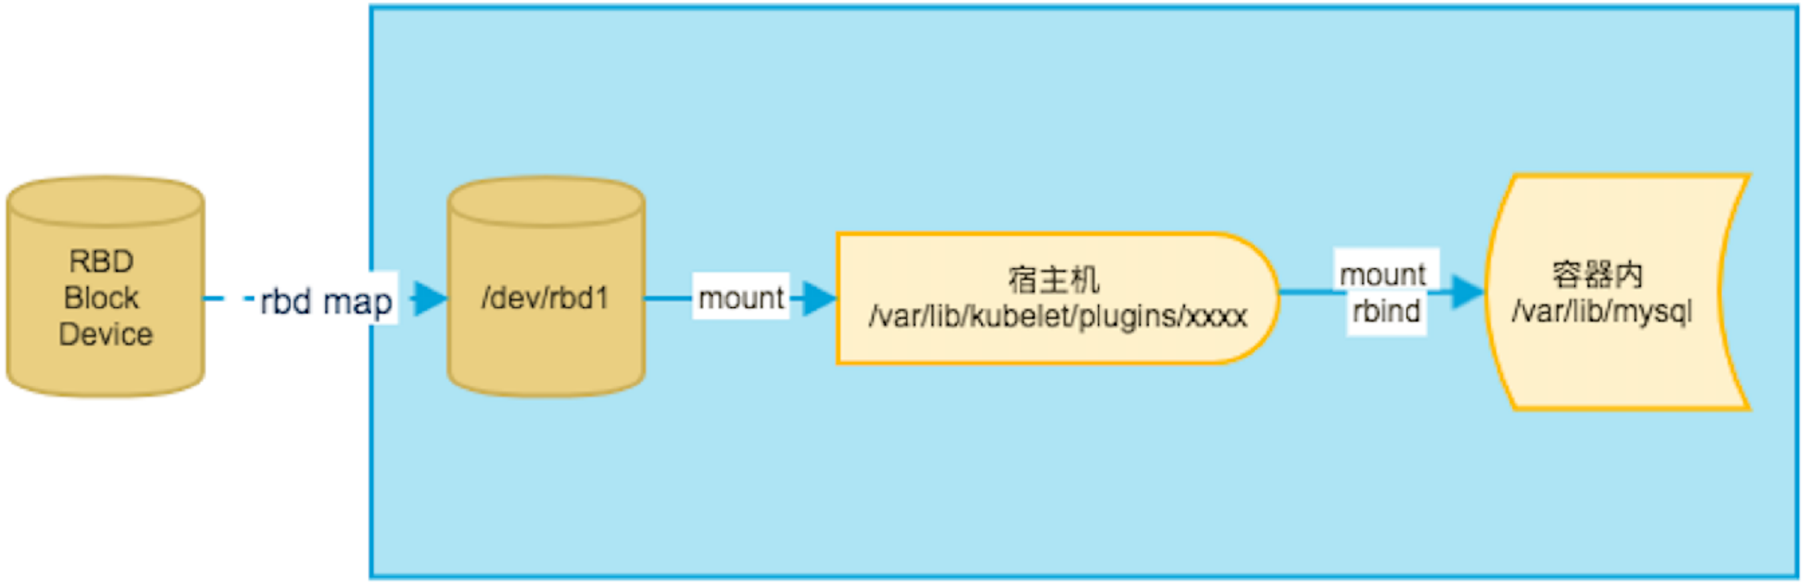

RBD Map：虚拟块设备

mount：格式化后，挂载文件系统到宿主机目录

mount rbind：挂载宿主机目录到容器进程内

递归挂载 Volume 的传递性

挂载模式：

shared：相互传递

slave：主从传递

private：互补传递 (1.6 仅支持 private 模式)

例：

原始根目录下挂载：/mnt/a /mnt/b /mnt/c

rbind 挂载：将原始根目录递归挂载到特定目录

原始根目录：卸载 /mnt/b

rbind：卸载 /mnt/b

	原始根目录/	rbind /
Shared	/mnt/a	/mnt/a
Slave	/mnt/a /mnt/c	/mnt/a
Private	/mnt/a /mnt/c	/mnt/a /mnt/b

坑

1. 容器 A 已 RO 方式挂载 RBD Volume: /var/lib/kubelet/plugins/v1
2. Node exporter 以 make-private 方式挂载宿主机根目录
3. 容器 A 销毁后，写在 RBD Volume 成功，但是 rbd umap 失败：因为 node-exporter 仍在 RO 挂载
4. 容器 B 以 RW 的方式挂载同一 RBD Volume，由于 node-exporter 仍在 RO 挂载，导致容器 B 挂载失败
5. Kubernetes 使用 lsblk 获取文件系统失败
6. Kubernetes 触发格式化磁盘，数据丢失

故障原因

Node-exporter

Node exporter 以 DaemonSet 方式运行，挂载了整个物理机根目录

Kubernetes 只支持 mount make-private 的方式，Volume 卸载不具有传递性

Ceph

Ceph red client 与服务端版本不一致，导致 lsblk 获取文件系统类型失败

Kubernetes

在获取文件系统失败时，直接格式化 Volume

故障反思

部署固化，自动化

固话各个组件部署流程

部署后，检查相关组件的版本号

错误日志收集、告警

收集各个系统组件的 warning、error、fatal 日志，并设置告警，及时跟进

收集宿主机系统日志，设置告警，及时跟进

Kubernetes

梳理 Kubernetes 对 Volume 相关处理逻辑

Node-exporter 不应以 make-private 方式递归挂载根目录

AI训练的业务情况

kubernetes 的优势

基于 kubernetes 的AI训练

一次踩坑经历

接下来的工作

主办：

自配置监控

创建 Kubernetes Services 时添加 annotation

- 监控数据抓取服务端口
- 监控数据抓取路径

Prometheus 自动发现服务，抓取监控数据

```
...
# The service being deployed exposes a metr
# scraped by Prometheus but metrics are exp
  prometheus.io/scrape:'true'
  prometheus.io/path:   /foo/bar/metrics
  prometheus.io/port:   '8080'
...
```

分布式训练

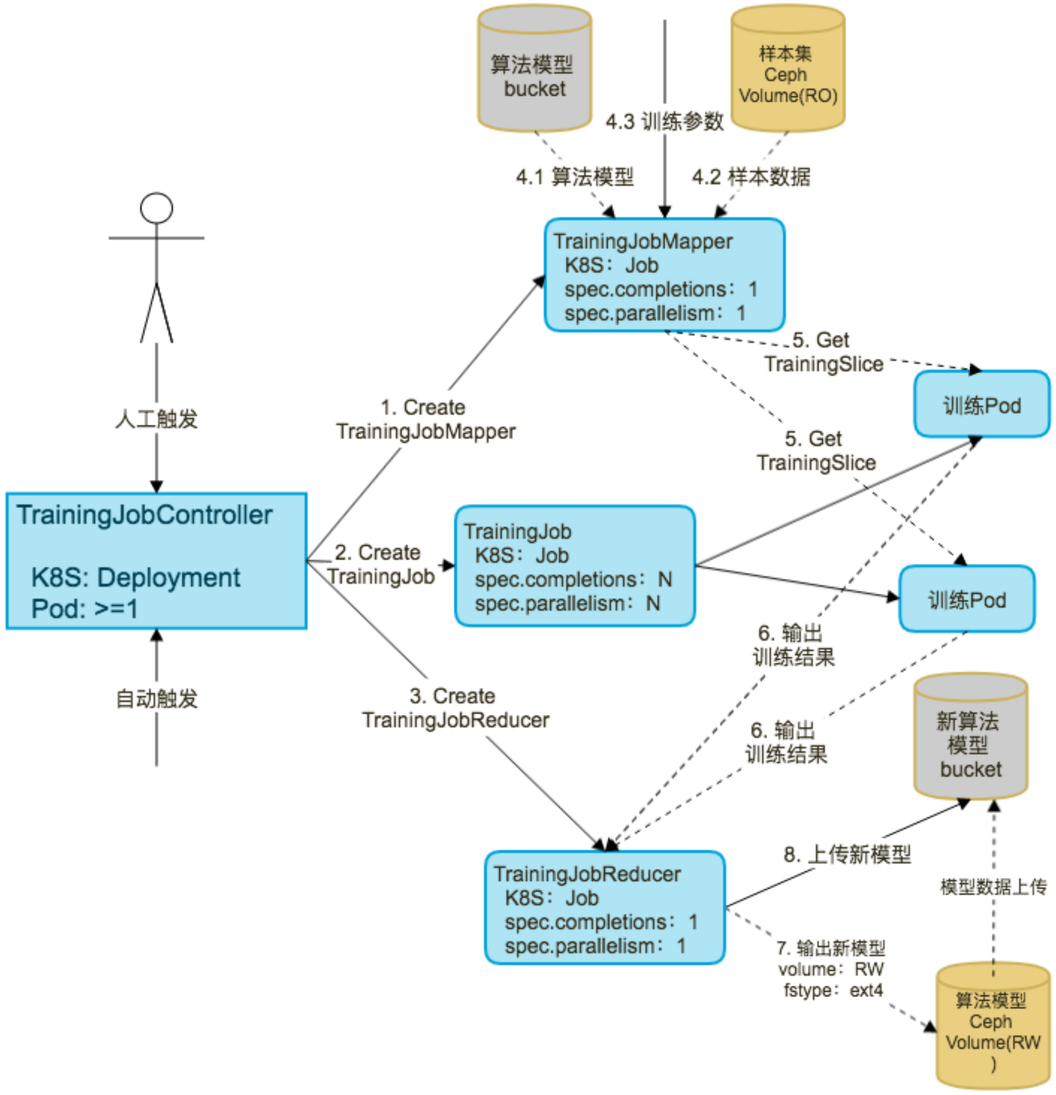
算法模型
bucket
样本集
Ceph
Volume(RO)
4.3 训练参数
4.1 算法模型
4.2 样本数据
TrainingJobMapper
K8S：Job
spec.completions：1
spec.parallelism：1
5. Get
TrainingSlice
训练Pod
人工触发
1. Create
TrainingJobMapper
5. Get
TrainingSlice
TrainingJobController
K8S: Deployment
Pod: >=1
2. Create
TrainingJob
TrainingJob
K8S：Job
spec.completions：N
spec.parallelism：N
训练Pod
6. 输出
训练结果
自动触发
3. Create
TrainingJobReducer
6. 输出
训练结果
新算法
模型
bucket
8. 上传新模型
模型数据上传
TrainingJobReducer
K8S：Job
spec.completions：1
spec.parallelism：1
7. 输出新模型
volume：RW
fstype：ext4
算法模型
Ceph
Volume(RW
)

Q&A

Thank you for your time

2017 China Kubernetes End User Conference
kubernetes 中国用户大会
KEUC 2017
2017.10.15 / 中国·杭州

主办：
CLOUD NATIVE COMPUTING FOUNDATION
caicloud 才云
K8S Meetup 中国社区